

OpenAI Responses·근거 답변 구현 및 시험 서버 실증 완료

검색 근거, 모델 선택, 안전한 보류, 장애와 복구를 하나의 AI Gateway 운영 계약으로 구현했습니다.

96 + 96 Tests · Real ANSWERED 5 Citations · Secret Scan 0 · Rollback Verified

TechFlow AI Gateway 0.4.0 · OpenAI Responses API · 2026-08-10

1. 완료 판정

Issue #44의 코드, 실 Provider, 서버 배포, 감사, 보류, 복구와 문서 자산화를 완료했습니다.

검증	결과	판정
Gateway	0.4.0 · Database/Vector ready	PASS
실 답변	ANSWERED · Citation 5	PASS
사전 보류	ABSTAINED · Generation 호출 없음	PASS
테스트	로컬 96 · 서버 격리 96	PASS
Secret	배포 파일 로그 Hit 0	PASS
복구	0.4 → 0.3 → 0.4	PASS

Issue #44 구현 기준은 충족했습니다. PR 병합 전까지 Issue는 열어 두고 검토 자산으로 제공합니다.

2. 답변 처리 구조

단계	입력	판정·출력
Retrieve	질문·Scope	최대 10개 D0 Chunk · RRF
Preflight	Source·Branch·Commit	보류 또는 승인 Profile
Generate	최소 Context	Strict JSON Schema
Postvalidate	Citation IDs	부분집합·Branch·Test-only 재검증
Return	검증 결과	ANSWERED·ABSTAINED·FAILED

- 원본 Repository는 OpenAI File·Vector Store에 업로드하지 않습니다.
- 모델은 스스로 라우팅하지 않으며 Gateway가 검색 Metadata로 한 번 결정합니다.
- 실패나 낮은 확신을 이유로 Terra에서 Sol로 자동 이중 호출하지 않습니다.
- 반환 Citation이 전달 Context에 없으면 답변을 ABSTAINED로 바꿉니다.

3. Provider·보안 계약

항목	고정값
Default	gpt-5.6-terra · medium · 단일 Repository/Commit
Escalation	gpt-5.6-sol · high · 승인된 복수 Repository/Commit
Responses	store=false · background=false · stream=false · tools=[]
Output	Strict JSON Schema
Identity	HMAC-SHA256 safety_identifier · 최대 64자
Audit	Model-Request/Response ID-Token-Latency-Status-Error
Raw retention	질문·Chunk·답변 0

GitHub에는 OPENAI_API_KEY와 OPENAI_PROJECT_ID Secret 이름만 존재하며 실제 값은 문서·PR·로그에 남기지 않습니다.

4. 실증 증거

항목	결과
실 답변	기본 Profile · Citation 5 · 6,184 ms
Usage	Input 6,002 · Output 620 Token
사전 보류	CLOUD_MAIN 근거 없음 · Generation 미호출
활성 Source	GENIE_MASTER · ACTIVE
검색 자산	34 File · 64 Chunk · 64 Embedding
코드 구조	15 Symbol · 45 Relation
Activepieces	6 Container 모두 Healthy
Disk	1,005 GiB · 가용 950 GiB · 사용률 2%

Canary는 답변 원문을 출력하지 않고 State, Profile, Citation 수, Answer 문자 수와 호출 여부만 기록했습니다.

5. 실 Provider에서 발견한 결함

결함	관측	수정
가명 식별자	67자 · HTTP 400	HMAC 출력 최대 64자
과대 라우팅	동일 Version 문서+코드를 Sol로 승격	단일 Repository/Commit은 Terra
상향 Timeout	Sol/high · 12초 정책 초과	승격 조건을 복수 구성요소로 한정

- 첫 실패는 PROVIDER_REJECTED/TERMINAL로 감사했습니다.
- 두 번째 실패는 PROVIDER_TIMEOUT/RETRYABLE로 감사했습니다.
- 오류 원문, 질문, Context와 답변은 감사 테이블에 저장하지 않았습니다.
- 수정 후 같은 실 데이터 경로에서 ANSWERED를 확인했습니다.

문서와 코드가 함께 검색됐다는 사실은 충돌이 아닙니다. Repository-Commit 경계를 모델 비용과 지연의 결정 기준으로 사용합니다.

6. 배포와 복구

단계	자산·결과
Backup	DB Dump · 기존 Image ID · Compose · Override · Checksum
Stage	별도 경로 빌드 · Network-none 96 Tests
Deploy	issue-44 Image · Gateway 0.4.0 Healthy
Rollback	issue-43 Image · Gateway 0.3.0 Healthy
Forward	issue-44 Image 복귀 · Database/Vector ready
Data	34/64/64/15/45 보존

최초 백업 경로

/home/ablecloud/techflow-ai-gateway/backups/issue44-predeploy-20260810T0230KST

- Base Compose와 OpenAI 운영자 Override를 항상 함께 지정합니다.
- Schema 추가가 없어 Image와 Compose 참조만으로 롤백했습니다.
- Activepieces Volume과 여섯 Container는 변경하지 않았습니다.

7. 운영 확인과 다음 단계

OpenAI 공식 문서상 `store=false`는 애플리케이션 저장을 끄지만 그 자체가 Zero Data Retention을 보장하지 않습니다. Project의 ZDR 또는 Modified Abuse Monitoring 적용 상태는 Organization Dashboard에서 운영자가 확인해야 합니다.

구분	조치
Data Controls	D1 이상 확장 전 ZDR/MAM 적용 상태 확인
Credential	대화에 직접 입력된 현재 API Key 회전
Issue #44	Draft PR 검토·병합 후 종료
Issue #45	Activepieces Push·승인·재색인 Flow 연동

현재 상태: IMPLEMENTED · DEPLOYED · REAL-PROVIDER VALIDATED · ROLLBACK VERIFIED

참고

<https://developers.openai.com/api/docs/guides/latest-model>

<https://developers.openai.com/api/docs/guides/structured-outputs>

<https://developers.openai.com/api/docs/guides/your-data>