

Parser·Chunk·Embedding·검색 구현 및 서버 실증 완료

승인된 ABLESTACK 소스를 실행하지 않고 검색 가능한 근거로 전환하는 AI Gateway 0.3.0 구현
보고서

34 Files · 64 Chunks · 64 Embeddings · 10 Source-pinned Results

GENIE_MASTER · master@3e3c5c364f5c7261b07d49fcbcd4f3605b91f3b1
시험 서버 · Mock Embedding · 외부 OpenAI 호출 0 · 2026-08-05

1. 완료 판정

Issue #43의 구현, 시험 서버 배포, 승인 GENIE Canary, 검색, 재시작 연속성, 격리 삭제 Drill, 문서와 PDF/PPTX 자산화를 완료했습니다.

영역	결과	판정
Gateway	0.3.0 · Healthy	PASS
Source	GENIE 34 / 34	PASS
Index	64 Chunk · 64 Embedding	PASS
Search	Top 10 · Commit/Path/Line	PASS
Delete	64/64/15/45 · 잔여 0	PASS
Tests	87 passed · 4 subtests	PASS

검색 근거 계층은 완료됐으며 답변 생성은 Issue #44까지 명시적으로 보류합니다.

검토자가 확인할 핵심

- Source Version과 인용 Commit이 동일한가
- 34개 Eligible File 전체가 성공한 후에만 활성화됐는가
- 실 Provider 호출 없이도 OpenAI Adapter 계약과 Secret 경계가 검증됐는가
- 철회 시 검색 제외와 파생 데이터 삭제가 재현 가능한가

2. 처리 아키텍처

단계	입력	출력	안전 경계
Parse	검증된 UTF-8 Blob	Chunk:Symbol-Relation	실행·Import-Build-Test 0
Embed	최대 24 KiB Chunk	3072차원 Vector	Runtime Secret File 전용
Retrieve	질문+Source Scope	상위 10개 근거	ACTIVE-D0 Scope 선적용
Generate	검색 근거	미구현	Issue #44까지 ABSTAINED

OpenAI 연계

- 공식 OpenAI Python SDK 2.53.0과 Embeddings API Adapter를 사용합니다.
- Model은 text-embedding-3-large, Dimension은 3072로 Profile에 고정합니다.
- 원본 Repository를 OpenAI File 또는 Vector Store에 업로드하지 않습니다.
- 감사에는 Provider·Model·Request ID·Token·Latency만 남기고 원문·Secret을 저장하지 않습니다.

이번 Canary는 Mock Provider입니다. 실 OpenAI Canary는 운영 API Key를 보호 파일로 주입한 뒤 동일 Adapter 경로에서 별도 수행합니다.

공식 참고

<https://developers.openai.com/api/reference/resources/embeddings/methods/create>

<https://developers.openai.com/api/docs/models/text-embedding-3-large>

3. Parser·Chunk·Embedding 계약

계약	설정	서버 결과
Parser	TREE_SITTER_V1 · Parser 13종	8 Parsed · 26 Fallback
Fallback	최대 160 Line · Overlap 20	결정론적 분할
Chunk	최대 24 KiB · UUIDv5	64개
Symbol	Package-Name-Signature-Line	15개
Relation	Import-Inheritance-Declaration-Reference	45개
Embedding	OPENAI_EMBEDDING_V1 · 3072	64개 · Batch 1

Hybrid Retrieval

- 후보 전에 Source Profile 또는 Compatibility Set, D0, ACTIVE를 필터합니다.
- FTS 20, Identifier 20, exact cosine 30 후보를 생성합니다.
- RRF k=60으로 결합하고 TEST_CODE Weight 0.6을 적용합니다.
- 최대 10개 Repository·Branch·Commit·Path·Line·Symbol 인용을 반환합니다.

현재 활성 Chunk 64개에서는 exact cosine이 가장 단순하고 재현성이 높습니다. HNSW는 50,000 Chunk Gate에서 재검토합니다.

4. 시험 서버 실증

항목	실측
Source	GENIE_MASTER · 34 / 34
Commit	3e3c5c364f5c7261b07d49fcbcd4f3605b91f3b1
Index	64 Chunk · 64 Embedding · 15 Symbol · 45 Relation
Gateway	0.3.0 · Healthy · pgvector ready
Runtime	UID 10001 · Read-only Root FS
Disk	1,005 GiB · 950 GiB available · 2% used
Isolation	Activepieces 6 Container all healthy

인용 예시

ablecloud-team/ablestack-genie / master / 3e3c5c... / genie-shell/README.md / lines 28-34

상위 결과는 Automation Controller와 AWX 개발환경 구성 절차를 승인 Commit의 Line Range로 반환했습니다.

재시작 영속성

- Gateway 재시작 후 Health 200과 Version 0.3.0을 확인했습니다.
- 재시작 후에도 Source ACTIVE, 34 / 34, Chunk-Embedding 64 / 64를 유지했습니다.
- OpenAI Key 환경변수 0건, Provider Audit은 Mock Embeddings 1건만 기록됐습니다.

5. 실패 보상과 삭제 Drill

최초 서버 실행에서 DB Row Alias와 JSONB Adapter 결함을 발견했습니다. 두 실패 모두 Source를 APPROVED로 복귀시키고 활성 Chunk 0건을 유지했습니다. 수정 후 새 Job과 새 역등기로 34 / 34 활성화에 성공했습니다.

상황	보상	검증
Parsing-DB 실패	Job FAILED	부분 활성화 0
Source 상태	APPROVED 복귀	재검토·재실행 가능
재실행	새 Job·새 역등기	SUCCEEDED
활성 전환	전체 파일 일치 후 원자 전환	34 = 34

격리 삭제 Drill

파생 데이터	삭제	잔여
Chunk	64	0
Embedding	64	0
Symbol	15	0
Relation	45	0

Live GENIE Index는 유지하고 임시 DB techflow_rag_issue43_drill에서 검증한 뒤 정확한 임시 DB만 제거했습니다.

6. 배포·백업·롤백

자산	경로·값
배포	/home/ablecloud/techflow-ai-gateway
Release	issue-43
Image	sha256:d767e54b...fdd3e
Backup	backups/issue43-20260805T1444KST
DB	techflow-rag.dump
Code	pre-deploy-code.tgz
Integrity	checksums.sha256

배포 절차

- Compose Rendering과 Digest 고정을 확인합니다.
- Tree-sitter Parser 13종을 Image Build 시 Prefetch합니다.
- 0005 Migration 적용 후 Table 19개와 Issue #43 Column 8개를 검증합니다.
- Gateway와 Reconciler만 갱신하고 Activepieces Volume은 변경하지 않습니다.

롤백

- 애플리케이션 오류는 백업된 이전 Image ID로 Gateway를 전환합니다.
- Schema 롤백은 DB 백업과 제품 책임자 승인 후 0005 down Migration을 적용합니다.
- 복원은 새 DB에서 먼저 검증하고 Activepieces와 분리해 전환합니다.

7. 다음 승인 지점

Issue #43은 검색 근거를 준비했습니다. 다음 Issue #44에서는 이 근거만 사용해 답변 생성과 보류 판정을 구현합니다.

순서	Issue #44 범위
1	OpenAI Responses Adapter
2	Structured Output과 Citation 사용 검증
3	근거 부족·충돌·Test-only ABSTAINED 판정
4	Terra 기본·Sol 제한 승격 Routing
5	운영 API Key 기반 실 Embedding Canary

권장 결정: Issue #43 PR을 검토·병합한 뒤, 운영 API Key를 보호 Secret으로 주입해 실 Embedding Canary를 먼저 증적하고 Issue #44 구현에 착수합니다.

관리 자산

- docs/reports/issue-43-parser-embedding-validation.md
- docs/runbooks/parser-embedding-retrieval.md
- docs/decisions/techflow-parser-embedding-retrieval.json
- output/issue-43-artifact-manifest.json

판정: IMPLEMENTED · DEPLOYED · VALIDATED