

D0 공개 문서 RAG PoC 상세 설계와 작업 분해

Issue #20 설계 완료·제품 책임자 승인 대기

설계 판정	공개 ABLESTACK 문서만 사용하는 RAG 경계를 확정하고, Activepieces-AI Gateway·PostgreSQL 책임을 분리했습니다. 구현은 #41~#46으로 분해했습니다.
-------	--

276	10	10	3	6
Markdown	APIs	Tables	Answer States	Work Items

대상	결과
상위 단계	Epic #3와 M0 Foundation 최종 종료
추적 Issue	#20 ABLESTACK 기술문서 RAG PoC
Source	ablecloud-team/ablestack-docs · D0 · 276 Markdown
구현 영향	이번 단계는 설계·검증 자산만 변경, 서버·Flow-Secret 변경 없음
다음 단계	설계 승인 후 #41 AI Gateway 골격

문서 상태 설계 완료·승인 대기

기준일 2026-08-03

1. 목표와 범위

Issue #20은 Community 질문과 사내 메신저 기술질문에 근거 기반 답변 초안을 제공하기 위한 최소 RAG 기반을 설계합니다. 자동 외부 게시, ABLESTACK 자원 변경, 고객별 D1~D3 지식은 포함하지 않습니다.

포함 범위

- 공개 ABLESTACK Markdown Source 등록·검역·승인·버전 추적
- Chunk·Embedding·PostgreSQL FTS·pgvector exact 검색과 RRF 결합
- 근거가 있는 답변, 오류와 실패 상태, Provider Adapter
- Source 철회와 파생 Chunk·Embedding·Cache 삭제
- Activepieces 수집·재색인·평가 Flow와 Golden Set 검증

명시적 제외

제외	이유
D1·D2·D3 지식	이번 PoC는 D0만 승인
AI Tool·Shell·API 실행	답변과 인프라 작업 경계 유지
자동 외부 게시	담당자 승인 제품 기능은 #23·#24 후속
고객별 Tenant 격리	P1 실증 이후 제품화 단계
HNSW	50,000 active chunks 전에는 exact 기준선 우선

2. 확인한 Source 기준선

공개 GitHub 저장소를 기준일에 직접 조사했습니다. Source Registry는 저장소·Branch·Commit·Path·Content Hash를 함께 보존하여 같은 문서의 버전과 삭제를 추적합니다.

50d50ad6	276	D0
Source Commit	docs/**/*.*.md	Classification

항목	결정
Repository	ablecloud-team/ablestack-docs
Default branch	master
허용 경로	docs/**/*.*.md
초기 파일 수	276
등급	D0 Public
등록 상태	REGISTERED → QUARANTINED → APPROVED → INDEXING → ACTIVE
철회 상태	WITHDRAWN → DELETION_REQUESTED → DELETED

승인 전 수집 금지	Allowlist에 일치해도 검역·분류·Reviewer 승인 전에는 검색 Index에 게시하지 않습니다.
------------	--

3. 아키텍처와 책임 경계

구성요소	소유 책임	소유하지 않는 것
Activepieces	변경 감지·승인 요청·Job 호출·평가 Schedule	Source 상태·검색·답변 정책
TechFlow AI Gateway	Registry·검역·검색·답변·삭제·품질	Flow UI·연결 자격증명
PostgreSQL / pgvector	전용 DB의 메타데이터·FTS·Vector·Lineage	제품 정책 판단
Model Provider	Embedding·Generation 호출	Source·보존·권한 결정
Channel Adapter	질문 수신·답변 초안 전달	자동 게시 결정

배포 형태

- Python 3.12 + FastAPI AI Gateway를 별도 Compose 서비스로 추가
- 기존 PostgreSQL 인스턴스에 전용 techflow_rag DB와 app/migration 역할 분리
- 자격증명은 런타임 Secret으로만 주입하고 문서·로그·DB에 저장하지 않음
- Health, readiness와 단계별 Job 상태를 Observer에 연결

경계 원칙	Flow 실행 성공은 RAG 품질 성공이 아닙니다. 답변 상태와 Citation 검증을 AI Gateway가 최종 판정합니다.
-------	--

4. API·데이터 계약

API	용도
GET /healthz	Process·DB·Vector Health
POST /v1/sources	Source Version 등록
GET /v1/sources/{sourceId}	Source 상태 조회
POST /v1/sources/{sourceId}/approve	검역 Source 승인
POST /v1/sources/{sourceId}/ingestions	수집 Job 생성
DELETE /v1/sources/{sourceId}	철회·삭제 요청
GET /v1/jobs/{jobId}	Job 상태 조회
POST /v1/rag/query	검색·근거 답변
POST /v1/evaluations/runs	평가 Run 생성
GET /v1/evaluations/runs/{runId}	평가 결과 조회

핵심 Table	책임
rag_source / rag_source_version	Source 상태·버전·Hash
rag_ingestion_job / rag_chunk	수집 Job·Chunk·Lineage
rag_embedding_profile / rag_chunk_embedding	모델 Profile·차원·Vector
rag_deletion_ledger	삭제 전파와 증적
rag_evaluation_case	승인된 Golden Question
rag_evaluation_run / rag_evaluation_result	Profile별 평가 결과

5. 검색과 근거 답변

초기 Corpus는 작으므로 exact vector 검색을 기준으로 사용합니다. PostgreSQL FTS와 cosine 결과를 각각 20개 수집한 뒤 RRF(k=60)로 결합해 상위 8개를 답변 Context로 사용합니다.

단계	초기값	Gate
Chunk	700 tokens, overlap 100	Heading·Source lineage 보존
Lexical	FTS candidate 20	제품·버전·상태 Filter
Vector	exact cosine candidate 20	Embedding 차원·모델 일치
Fusion	RRF k=60	Source당 최대 3 chunks
Context	top 8	중복·비활성 Source 제거
Answer	ANSWERED / ABSTAINED / FAILED	ANSWERED는 Citation 필수

응답 원칙

- 근거가 부족하거나 충돌하면 ABSTAINED
- Provider·DB·정책 장애는 FAILED와 허용된 오류 코드
- Prompt·응답 원문은 기본 영속 저장하지 않음
- Citation은 Source ID·Version·Commit·Path·Chunk ID를 포함
- AI 출력은 Shell·API·Activepieces Flow·ABLESTACK 작업을 직접 호출하지 않음

HNSW 전환 Gate

Active Chunk 50,000 이상에서 latency와 recall benchmark를 수행하고 품질 회귀가 없을 때만 별도 ADR로 활성화합니다.

6. 보안·삭제·장애 처리

영역	정책
Quarantine	Secret·개인정보·악성 지시·Binary·허용 경로 검사
Prompt Injection	검색 문서는 데이터로 취급, System 지시를 변경하지 못함
Egress	승인 GitHub·Provider 목적지만 허용
Credential	런타임 주입, 로그·DB·문서 저장 금지
Deletion	요청 즉시 검색 제외, 파생 삭제 SLO 최대 7일
Retry	같은 idempotency key로 중복 Version·Chunk 방지
Rollback	Source 비활성화 → Index 제외 → 직전 Gateway/Image 복귀
Evidence	건수·상태·Correlation ID만 보존

삭제 검증

- Source와 모든 Version을 INACTIVE로 전환해 즉시 검색에서 제외
- Lineage로 Document·Chunk·Embedding·Cache·평가 연결 탐색
- Primary와 Index에서 삭제 후 잔여 건수 0 확인
- 백업 복구 시 deletion ledger 재적용
- 삭제 시각·대상 건수·결과만 감사 증적으로 보존

Fail Closed

분류·권한·출처·모델 계약 또는 삭제 상태가 불명확하면 수집과 답변을 중단합니다.

7. 품질 기준과 테스트

분류	검증
Contract	JSON Schema 성격의 12개 자동 테스트
Retrieval	Recall@8, MRR@8, Source diversity
Grounding	Citation precision-coverage, Unsupported claim
Safety	D1-D3 거부, Prompt Injection, Secret-PII 검출
Operations	중복 Sync, 부분 실패 Retry, Provider timeout
Deletion	즉시 검색 제외와 Lineage 잔여 0
E2E	GitHub Source 변경 → 승인 → 색인 → 질문 → 초안 전달

PoC 목표 Gate

지표	목표
Golden Set retrieval Recall@8	≥ 0.85
Citation precision	≥ 0.95
근거 없는 ANSWERED	0건
D1-D3 수집·검색	0건
중복 Chunk	0건
삭제 Drill	검색 제외 즉시, 파생 삭제 테스트 ≤ 15분
API E2E 성공률	≥ 95%

제품화 전제

PoC 수치는 사내 실증 기준이며 고객 제품 Gate는 실제 운영 데이터로 재산정합니다.

8. 작업 분해와 승인 요청

Issue	작업	선행
#41	AI Gateway 골격·API 계약·DB Schema	Issue #20 승인
#42	Source Registry·Quarantine·승인	#41
#43	Chunk·Embedding·Hybrid Retrieval·Lineage 삭제	#42
#44	근거 답변·Provider Adapter·보류 정책	#43
#45	Activepieces 수집·재색인·평가 Flow	#42, #43, #44
#46	Golden Set·보안·품질·E2E·운영 자산	#44, #45

제품 책임자 승인 항목

- 초기 Source: ablecloud-team/ablestack-docs 공개 Markdown 276개
- 책임 경계: Activepieces 오케스트레이션, AI Gateway 정책·상태
- 검색: exact cosine + FTS + RRF, HNSW 비활성
- 답변: Citation 필수, ANSWERED·ABSTAINED·FAILED
- 보안: D0 only, Tool 직접 실행 금지, 원문 기본 미저장
- 삭제: 즉시 검색 제외, 파생 데이터 최대 7일

다음 실행

위 설계를 승인하고 Provider endpoint·embedding/generation model-dimension-Reviewer를 런타임 입력으로 제공하면 #41을 시작합니다.

참조: ADR-0008, Issue #20 상세 설계, RAG 계약 JSON, 개발 Runbook, 공식 pgvector-GitHub API 문서