

문서·소스코드와 OpenAI를 잇는 RAG PoC 개정 설계

Responses API · Embeddings API · 로컬 검색 · 모델 라우팅 설계 보고서

항목	결정
제품 런타임	OpenAI Responses API
Vector 생성	OpenAI Embeddings API
기본 답변	gpt-5.6-terra · medium
선택 승격	gpt-5.6-sol · high
Embedding 기준선	text-embedding-3-large · 3,072
상태	제품 책임자 승인 대기

Credential, Prompt, 응답 원문, Source 원문과 사용자 식별정보는 이 보고서에 포함하지 않는다.

1. 기존 설계의 부족한 부분과 결론

기존 설계는 AI Gateway의 책임은 정의했지만 실제 API, 모델, 전송 단위, 보존 경계와 ChatGPT Work·Codex의 역할을 구현 수준으로 고정하지 않았다.

방식	결정	제품 내 역할
Responses API	채택	고객 질의의 구조화 답변
Embeddings API	채택	Chunk·Query Vector
Batch API	조건부	대량 색인·재색인·평가
ChatGPT Work	런타임 제외	사람 중심 분석·보고 보조
Codex	런타임 제외	개발·코드 리뷰 보조
Agents SDK·Tool	P1 제외	현재는 Tool 없는 단일 답변

결론

- 제품 백엔드는 OpenAI 공식 Python SDK로 Responses·Embeddings API를 직접 호출한다.
- ChatGPT Work와 Codex의 라이선스·세션에 제품 Runtime을 결합하지 않는다.

2. 하단 데이터 흐름

단계	TechFlow 내부	OpenAI 경계
수집	고정 Commit Tree-Blob 읽기	전송 없음
분석	검역·Parser·Chunk·Symbol·Lineage	전송 없음
색인	Chunk Metadata·Vector 저장	D0 최소 Chunk Embedding
검색	FTS·Identifier·pgvector·RRF	전송 없음
답변	최대 10개 Context·정책 구성	Responses API 1회
검증	Schema·Citation·Source Version 재검증	반환 ID·Usage만 수신

원본 Repository를 OpenAI File·Vector Store·ChatGPT Project에 업로드하지 않는다. 최종 선택한 D0 Chunk와 Citation Metadata만 전송한다.

답변 상태

- Citation이 일치하면 ANSWERED
- 근거·Branch·Compatibility·Test-only·Citation이 불충분하면 ABSTAINED
- Provider·DB·Gateway 장애는 FAILED

3. 모델 Profile과 효율화

Profile	Model	Effort	선택 규칙
DEFAULT_V1	gpt-5.6-terra	medium	일반 기술지원·명확한 Profile
ESCALATION_V1	gpt-5.6-sol	high	사전 검출된 소스 충돌·복수 구성요소
EMBEDDING_V1	text-embedding-3-large	3,072	한국어·영어·코드 검색 기준선

비용·품질 균형

- Terra를 기본으로 사용해 품질과 비용을 균형화한다.
- Sol 승격은 모델이 아니라 Gateway의 결정적 규칙이 호출 전에 판정한다.
- 낮은 자신감이나 오류만으로 자동 두 번째 호출을 만들지 않는다.
- #43에서 1,536·1,024 Dimension과 text-embedding-3-small을 같은 Golden Set으로 비교한다.

변경 통제

- 요청 Model ID와 반환 Model ID를 함께 기록한다.
- 운영은 가능한 Snapshot을 고정하고 변경 시 새 Profile Version과 회귀 평가를 요구한다.

4. Source·검색 경계

범위	기준
저장소	7개 저장소 · 9개 Source Profile
Cloud	main · ablestack-diplo · ablestack-europa 독립
기준선	허용 파일 39,836개
검색	FTS 20 + Identifier 20 + exact cosine 30
결합	RRF k=60 · 최종 10 · Version당 4
Cross Repository	승인된 Compatibility Set만
Test	보강 근거 · 단독 ANSWERED 금지

Branch·Commit Filter는 후보 생성 전에 적용한다. 서로 다른 Cloud Branch는 어떤 RRF 단계에서도 결합하지 않는다.

Citation

- Repository·Branch·Commit·Path·Start/End Line·Symbol·Chunk ID
- Provider가 반환한 Citation ID를 현재 Context와 Source Version에 대해 Gateway가 다시 확인한다.

5. 데이터·보안 경계

통제	설계
등급	P1 Provider 전송은 D0만
요청 저장	Responses store=false
도구	Tool-Web-File Search-Code Interpreter-MCP 0
Provider 저장소	OpenAI Files-Vector Stores 사용 금지
식별자	단방향 가명화 safety_identifier
Credential	Secret Store 런타임 주입
감사	Request-Response ID-Model-Token-Latency-상태만
원문	Prompt-응답-코드 원문 영속 저장 0

store=false는 기본 Abuse Monitoring 보존까지 제거한다는 뜻이 아니다. 운영 전 API Organization·Project의 ZDR·MAM·Data Residency 상태를 확인·기록한다.

향후 D1 이상

- ZDR 또는 MAM 적격성과 승인, ACL·삭제 자동화, 지역 처리 결정을 별도 Gate로 요구한다.

6. API·DB 계약 v1.3

계약	결과
Gateway API	11개
논리 Table	15개
Source Profile	9개
Work Item	#41~#46
Query 상태	ANSWERED·ABSTAINED·FAILED
Contract Tests	29건

추가 Table

- rag_provider_call: Query·Evaluation ID, Provider Request·Response ID, Model Profile, Token·Latency·상태·Error Code
- Raw Prompt·Raw Response·Credential·Source 원문은 저장하지 않는다.

#41 구현 경계

- Provider Profile Schema와 Mock Responses·Embeddings Adapter 계약까지 구현한다.
- 실제 OpenAI 호출은 #43 Embeddings, #44 Responses에서 수행한다.

7. 장애·비용·품질 Gate

항목	초기 기준
Connect Timeout	3초
전체 Timeout	12초
재시도	429·5xx·Network Timeout 최대 3회
Circuit Breaker	5분·최소 10건·실패율 50%·60초 Open
Structured Output	유효율 100%
Citation 사후 검증	100%
Provider Tool Call	0건
승인 없는 Model 변경	0건
Golden Set	50개 · Code 20개 이상

판정

- Provider 오류를 오래된 답변이나 Mock 결과로 대체하지 않고 FAILED로 반환한다.
- Prompt Cache는 P1에서 명시 활성화하지 않고 실제 비용·지연·Data Control을 측정한 뒤 결정한다.

8. 구현 순서

Issue	구현
#41	AI Gateway-Provider Profile-15 Table-Mock Adapter
#42	7개 저장소-9 Profile Registry-검역-승인
#43	Parser-OpenAI Embeddings-Hybrid Retrieval-삭제
#44	OpenAI Responses-Routing-Structured Output-Citation 검증
#45	Activepieces 수집-재색인-평가 Flow
#46	모델-비용-품질-보안-E2E

다음 단계는 #41 구현이지만, ADR-0009와 구조화 계약 v1.3의 제품 책임자 승인 전에는 구현을 시작하지 않는다.

배포 전 입력

- OpenAI API Organization-Project와 API Key
- ZDR-MAM-Data Residency 상태
- 계정에서 사용 가능한 Model Snapshot 또는 Alias
- RAG DB Credential-GitHub 인증 방식-평가 Reviewer

9. 승인 요청

OpenAI 런타임 설계를 승인하면 #41의 Provider Profile-DB-Mock Adapter 구현부터 시작한다.

승인 항목	제안
제품 Runtime	Responses API + Embeddings API
기본/승격	Terra medium / Sol high
Embedding	text-embedding-3-large · 3,072
Repository 전달	금지 · 로컬 검색 결과만 전송
Tool-Agent	P1 금지
Data Control	운영 전 ZDR-MAM-Residency 확인
Work-Codex	운영·개발 보조, Runtime 제외

자산

- ADR-0009, 상세 설계, 계약 v1.3, Runbook, GitHub #41·#44
- PDF 보고서, PPTX/PDF 발표자료, 15-file Artifact Manifest
- #41 실제 구현은 승인 후 별도 실행